

1. Giriş

Makine öğrenmesi, verilerden örüntüler öğrenerek sınıflandırma, tahmin ve karar destek süreçlerinde kullanılan önemli bir yapay zekâ alanıdır. Özellikle sağlık alanında makine öğrenmesi yöntemleri; hastalıkların erken teşhisi, risk gruplarının belirlenmesi ve klinik karar destek sistemlerinin geliştirilmesi amacıyla yaygın olarak kullanılmaktadır. Kalp hastalıkları, dünya genelinde önemli sağlık problemlerinden biri olduğu için bu alanda yapılan tahmin çalışmaları büyük önem taşımaktadır.

Klasik makine öğrenmesi modellerinde genellikle tek bir model eğitilerek tahmin yapılır. Ancak tekil modeller bazı veri setlerinde aşırı öğrenme, düşük genelleme başarısı veya dengesiz tahmin problemleri gösterebilir. Bu nedenle birden fazla modelin birlikte kullanıldığı kolektif öğrenme yöntemleri geliştirilmiştir. Kolektif öğrenme, birden fazla öğrenicinin tahminlerini birleştirerek daha güçlü ve güvenilir sonuçlar elde etmeyi amaçlayan bir yaklaşımdır (Dietterich, 2000).

Kolektif öğrenme yöntemlerinden biri olan Random Forest, çok sayıda karar ağacını bir araya getirerek sınıflandırma işlemi yapar. Her karar ağacı farklı veri örnekleriyle eğitilir ve nihai karar çoğunluk oyu ile belirlenir. Bu yaklaşım, tek bir karar ağacına kıyasla aşırı öğrenme riskini azaltır ve genellikle daha kararlı sonuçlar üretir (Breiman, 2001).

Boosting yöntemleri ise zayıf öğrenicileri ardışık olarak eğiterek güçlü bir model oluşturmayı amaçlar. AdaBoost algoritması, yanlış sınıflandırılan örneklere daha fazla ağırlık vererek sonraki modellerin bu örneklere odaklanmasını sağlar (Freund ve Schapire, 1997). Gradient Boosting ise her yeni modelin önceki modelin hatalarını azaltmasına dayalı olarak çalışan güçlü bir kolektif öğrenme yöntemidir (Friedman, 2001).

Bu çalışmada, kalp hastalığı tahmini problemi için kolektif öğrenme yöntemleri kullanılmıştır. Çalışmanın amacı, seçilen veri seti üzerinde farklı kolektif öğrenme algoritmalarını uygulamak ve elde edilen başarı sonuçlarını karşılaştırmaktır. Bu kapsamda Random Forest, AdaBoost, Gradient Boosting ve Voting Classifier yöntemleri kullanılmıştır.

2. Materyal ve Metod

2.1 Kullanılan Veri Seti

Bu çalışmada kalp hastalığı tahmini için Heart Disease Dataset¹ kullanılmıştır. Veri seti, bireylerin çeşitli sağlık göstergelerini içermektedir. Bu göstergeler arasında yaş, cinsiyet, göğüs ağrısı tipi, dinlenme kan basıncı, kolesterol değeri, açlık kan şekeri, elektrokardiyografi sonucu, maksimum kalp atış hızı ve egzersize bağlı anjina gibi değişkenler bulunmaktadır.

¹ <https://www.kaggle.com/datasets/ritwikb3/heart-disease-cleveland?resource=download>

Veri setindeki hedef deęişken, bireyde kalp hastalığı bulunup bulunmadığını göstermektedir. Bu nedenle problem bir ikili sınıflandırma problemi olarak ele alınmıştır.

Hedef deęişken genel olarak řu řekilde yorumlanmıştır:

0 = Kalp hastalığı yok

1 = Kalp hastalığı var

Veri seti modelleme sürecinden önce bağımsız deęişkenler ve hedef deęişken olarak ayrılmıştır. Daha sonra veri seti eğitim ve test olmak üzere iki parçaya bölünmüştür. Eğitim verisi modellerin öğrenmesi için, test verisi ise modellerin daha önce görmediğı veriler üzerindeki başarısını ölçmek için kullanılmıştır.

2.2 Veri Ön İşleme

Veri ön işleme aşamasında ilk olarak veri seti Python programlama dili ile okunmuştur. Veri setindeki sütunlar, veri tipleri ve eksik deęerler kontrol edilmiştir. Model başarısını olumsuz etkileyebilecek eksik deęerler ve veri uyumsuzlukları incelenmiştir.

Bu çalışmada uygulanan temel veri ön işleme adımları řunlardır:

- Veri setinin okunması
- Eksik deęer kontrolü
- Bağımsız deęişkenler ve hedef deęişkenin ayrılması
- Eğitim ve test veri setlerinin oluşturulması
- Sayısal verilerin ölçeklendirilmesi

Veri seti, eğitim ve test verisi olarak ayrılmıştır. Genel olarak verinin %80'i eğitim, %20'si test amacıyla kullanılmıştır. Sayısal deęişkenlerin farklı ölçeklerde olmasından dolayı **StandardScaler** yöntemiyle ölçeklendirme işlemi uygulanmıştır.

2.3 Kullanılan Yöntemler

Bu çalışmada dört farklı kolektif öğrenme yöntemi kullanılmıştır:

1. Random Forest
2. AdaBoost
3. Gradient Boosting
4. Voting Classifier

2.3.1 Random Forest

Random Forest, bagging tabanlı bir kolektif öğrenme yöntemidir. Birden fazla karar ağacının birlikte çalışmasıyla sınıflandırma yapar. Her karar ağacı veri setinin farklı alt örnekleriyle eğitilir. Sınıflandırma problemlerinde nihai karar, karar ağaçlarının çoğunluk oyu ile verilir.

Bu yöntem, tek karar ağacına göre daha kararlı sonuçlar verebilir ve aşırı öğrenme riskini azaltabilir (Breiman, 2001).

2.3.2 AdaBoost

AdaBoost, boosting yaklaşımına dayalı bir kolektif öğrenme algoritmasıdır. Bu yöntemde zayıf öğreniciler ardışık olarak eğitilir. Önceki modelin yanlış sınıflandırdığı örneklerle daha fazla ağırlık verilerek sonraki modellerin bu örneklerle odaklanması sağlanır. Böylece zayıf öğreniciler bir araya getirilerek güçlü bir sınıflandırıcı elde edilir (Freund ve Schapire, 1997).

2.3.3 Gradient Boosting

Gradient Boosting, boosting tabanlı bir diğer kolektif öğrenme yöntemidir. Bu yöntemde her yeni model, önceki modelin yaptığı hataları azaltmaya çalışır. Gradient Boosting algoritması, kayıp fonksiyonunu minimize etmeye dayalı olarak çalışır ve birçok sınıflandırma probleminde başarılı sonuçlar verebilir (Friedman, 2001).

2.3.4 Voting Classifier

Voting Classifier, farklı makine öğrenmesi modellerinin tahminlerini birleştirerek nihai kararı veren bir kolektif öğrenme yöntemidir. Bu çalışmada Voting Classifier içerisinde Logistic Regression, Decision Tree ve K-Nearest Neighbors algoritmaları kullanılmıştır. Modellerin tahminleri çoğunluk oyu mantığıyla birleştirilmiştir.

2.4 Kullanılan Başarı Ölçüm Kriterleri

Modellerin performansını değerlendirmek için Accuracy, Precision, Recall ve F1-Score ölçütleri kullanılmıştır. Bu ölçütler sınıflandırma problemlerinde yaygın olarak kullanılmaktadır (Powers, 2011).

Accuracy

Accuracy, modelin doğru tahmin ettiği örneklerin toplam örneklere oranını gösterir.

$$\text{Accuracy} = \text{Doğru Tahmin Sayısı} / \text{Toplam Tahmin Sayısı}$$

Precision

Precision, modelin pozitif olarak tahmin ettiği örnekler arasında gerçekten pozitif olanların oranını gösterir. Bu çalışmada pozitif sınıf, kalp hastalığı bulunan bireyleri ifade etmektedir.

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

Recall

Recall, gerçekten pozitif olan örneklerin ne kadarının doğru tahmin edildiğini gösterir. Sağlık alanındaki problemlerde recall değeri oldukça önemlidir çünkü hasta bireylerin doğru tespit edilmesi beklenir.

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

F1-Score

F1-Score, precision ve recall değerlerinin harmonik ortalamasıdır. Precision ve recall arasında dengeli bir değerlendirme yapmak için kullanılır.

$$\text{F1-Score} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

3. Deneysel Çalışmalar

Deneysel çalışmalarda veri seti öncelikle eğitim ve test verisi olarak ayrılmıştır. Daha sonra Random Forest, AdaBoost, Gradient Boosting ve Voting Classifier modelleri eğitim verisi üzerinde eğitilmiştir. Eğitilen modeller test verisi üzerinde denenmiş ve elde edilen tahmin sonuçları başarı ölçütleriyle değerlendirilmiştir.

Çalışmada kullanılan modellerin test verisi üzerindeki başarı sonuçları Tablo 1’de verilmiştir.

Tablo 1. Kolektif öğrenme modellerinin başarı sonuçları

	Model	Accuracy	Precision	Recall	F1-Score
0	Random Forest	0.885246	0.818182	0.964286	0.885246
1	AdaBoost	0.885246	0.818182	0.964286	0.885246
2	Gradient Boosting	0.852459	0.787879	0.928571	0.852459
3	Voting Classifier	0.868852	0.794118	0.964286	0.870968

Tablo 1’de görüldüğü üzere kolektif öğrenme modelleri birbirine yakın başarı sonuçları üretmiştir. Modeller arasında en yüksek accuracy değeri Random Forest ve AdaBoost modellerinde 0.885246 olarak elde edilmiştir. Voting Classifier modeli ise 0.86885 accuracy değeri ile diğer modellere yakın ve dengeli bir performans göstermiştir.

Precision değerleri incelendiğinde Random Forest ve AdaBoost modellerinin 0.818182 değeriyle en yüksek precision sonucunu verdiği görülmektedir. Bu durum, bu modellerin kalp hastalığı var olarak tahmin ettiği örneklerde daha isabetli sonuçlar ürettiğini göstermektedir.

Recall değerleri açısından bakıldığında Random Forest, AdaBoost ve Voting Classifier modelleri 0.964286 değeriyle en yüksek sonucu elde etmiştir. Sağlık alanındaki sınıflandırma problemlerinde recall değeri oldukça önemlidir. Çünkü kalp hastalığı bulunan bireylerin

doğru şekilde tespit edilmesi, modelin pratik kullanımı açısından kritik bir başarı göstergesidir.

F1-Score değerleri karşılaştırıldığında en yüksek sonucun Random Forest ve AdaBoost modellerinde 0.885246 olarak elde edildiği görülmektedir. F1-Score, precision ve recall değerlerini birlikte değerlendirdiği için modellerin genel dengesini göstermektedir. Bu açıdan Random Forest ve AdaBoost modellerinin veri seti üzerinde daha dengeli bir sınıflandırma performansı sunduğu söylenebilir.

Genel olarak değerlendirildiğinde, Random Forest ve AdaBoost modelleri hem precision hem recall hem de F1-Score açısından başarılı sonuçlar üretmiştir. Gradient Boosting modeli accuracy açısından başarılı olsa da precision ve F1-Score değerleri diğer modellere göre daha düşük kalmıştır. Voting Classifier modeli ise recall açısından yüksek başarı göstermiş, ancak precision ve F1-Score değerlerinde Random Forest ve AdaBoost modellerinin gerisinde kalmıştır.

Bu sonuçlara göre, kullanılan veri seti üzerinde en dengeli ve başarılı modellerin Random Forest ve AdaBoost olduğu sonucuna ulaşılmıştır.

4. Sonuçlar

Bu çalışmada kalp hastalığı tahmini için Random Forest, AdaBoost, Gradient Boosting ve Voting Classifier olmak üzere dört farklı kolektif öğrenme yöntemi uygulanmıştır. Modellerin başarıları Accuracy, Precision, Recall ve F1-Score ölçütleri ile değerlendirilmiştir.

Elde edilen deneysel sonuçlara göre Random Forest ve AdaBoost modelleri en başarılı sonuçları üretmiştir. Her iki model de 0.885246 accuracy, 0.818182 precision, 0.964286 recall ve 0.885246 F1-Score değerlerine ulaşmıştır. Bu durum, Random Forest ve AdaBoost modellerinin kalp hastalığı tahmini probleminde dengeli ve güvenilir sonuçlar verdiğini göstermektedir.

Sonuç olarak, bu çalışmada kolektif öğrenme yöntemlerinin kalp hastalığı tahmini için etkili biçimde kullanılabileceği görülmüştür. Özellikle Random Forest ve AdaBoost modelleri, elde edilen performans değerleri dikkate alındığında bu veri seti için en uygun modeller olarak değerlendirilebilir.

Kaynakça

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- Dietterich, T. G. (2000). Ensemble methods in machine learning. *Multiple Classifier Systems*, 1–15.
- Freund, Y., & Schapire, R. E. (1997). A decision-theoretic generalization of on-line learning and an application to boosting. *Journal of Computer and System Sciences*, 55(1), 119–139.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232.
- Powers, D. M. W. (2011). Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, 2(1), 37–63.
- UCI Machine Learning Repository. (t.y.). *Heart Disease Dataset*. University of California, Irvine.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.